

Clasificación de rendimiento de jugadores de Fútbol Americano

Gonzalo Merino y Federico García Brión

Facultad de Ingeniería,
Universidad de Buenos Aires
<http://fi.uba.ar>

Abstract. En este presente trabajo se utilizaron datos oficiales de la NFL y sus concursos de selección de jugadores para poder predecir en base a estos qué tan bueno termina siendo un jugador. Para ello se utilizó una *red neuronal* que clasifica a los mismos entre malo, regular y bueno.

Keywords: Red Neuronal, NFL, clasificación, Perceptron Multicapa

1 Introducción

La NFL (liga de futbol americano nacional, por sus siglas en español) es la liga deportiva más grande de los Estados Unidos, y una de las más grandes del mundo. Anualmente, la NFL representa decenas de millones de dólares en contratos de televisión, publicidad, etc y como en toda liga, tener un equipo competitivo es de vital importancia.

Una vez al año, los equipos de la NFL se reúnen para seleccionar, en orden, a los mejores jugadores del fútbol americano colegial, en lo que se conoce como el Draft de la NFL. Este Draft se convierte así en la principal fuente de talento de la que dependen los equipos para mantener su competitividad y es por esto que, cada año, invierten millones de dólares y contratan a cientos de personas para determinar, con la mayor precisión posible, que jugadores son los mejores y más aptos para el nivel de competición de la liga.

De esta forma, llegamos al problema que este trabajo pretende resolver. En base a variables conocidas, busquemos, mediante técnicas de Machine Learning, predecir que jugadores tendrán un mejor o peor desempeño en la NFL. Desde un punto de vista económico, la utilidad de resolver este problema es evidente, pero no es un problema trivial. La respuesta a esta pregunta, si bien no sería una declaración definitiva ya que no contempla cuestiones intangibles como pasión, liderazgo y ética de trabajo, podría servir para agregar más información al proceso de investigación de los jugadores colegiales y asistir en el proceso de selección a los distintos equipos.

2 Descripción del Problema

Como decíamos en el apartado anterior, la NFL cuenta con una *Reunión Anual de Selección de Jugadores de la NFL*[1], también conocida como *Draft de*

la *NFL*, en la cual los equipos de la liga tienen la oportunidad de seleccionar los mejores talentos del fútbol americano universitario. Los datos de estos *Draft* fueron progresando a lo largo del tiempo y ahora con la tecnología pasaron a ser digitalizados. Los más recientes son los que se encuentran de forma pública y accesible.

Para nuestro problema puntual, buscaremos analizar, en base a los datos disponibles, la performance futura de un jugador en la liga, tanto en retrospectiva (teniendo en cuenta la posición y el equipo que seleccionó al jugador en un determinado draft) como predictiva (sin estos datos de la selección en sí misma, a fin de poder analizar el valor de ese jugador para seleccionarlo en el draft).

Entre los datos de los *Draft* tenemos:

- **Year:** Año del Draft
- **Rnd, Pick, DP:** Ronda en la que entraron y fueron escogidos (estos se usarán para analizar la selección realizada en retrospectiva, es decir, una vez realizado el Draft en cuestión)
- **Tm:** Equipo que los seleccionó (también para análisis retrospectivo de la selección)
- **Pos:** Posición en la cual juegan
- **Age:** Edad al momento de realizarse el Draft
- **College:** Universidad de dónde provienen
- **SPORQ[2]:** Medición de aptitud física y rendimiento, aproximación al SPARQ de Nike, en base a resultados obtenidos durante el proceso de evaluación previo al Draft (particularmente el evento conocido como NFL Draft Combine)
- **Grade:** Calificación de expertos en la materia, provenientes de la página oficial de la NFL[3] y Jeff Feyerer un reconocido periodista/analista[4]
- **CarAV:** Puntuación según el sitio Pro Football Reference[5] del rendimiento del jugador en la(s) temporada(s) que disputo con su equipo (datos actualizados al final de la temporada 2018/19)

Por último, aclaramos que utilizaremos la feature CarAV para categorizar a los jugadores en 3 clases (Bueno, Regular y Malo) en base al rendimiento promedio a lo largo de su carrera.

Asimismo, esta clasificación será la que en definitiva intentaremos predecir utilizando la red neuronal.

3 Solución Propuesta

Para resolver este problema, consideraremos las dos partes del mismo, como dijimos anteriormente.

3.1 Retrospección del Draft

Set de Datos. Para esta parte, tendremos en cuenta las siguientes características:

NOTA: Todas estas características fueron normalizadas y escaladas posteriormente para facilitar la convergencia del algoritmo.

- **DP Normalizado:** se utilizará una categorización (entre 1 y 10) de la posición en la que se seleccionó al jugador.
- **Tm Normalizado:** esta característica consiste de un valor asignado al jugador en base al equipo que lo seleccionó. Será un número entre 0 y 33 (teniendo en cuenta la existencia de 32 equipos, más 2 equipos de expansión en los últimos años)
- **Pos Normalizado:** consiste de un valor asignado al jugador en base a la posición que ocupó durante su carrera universitaria. En caso de haber tenido más de una, se utilizará su posición predominante. Será un número entre 0 y 14.
- **Age Normalizado:** consiste de la edad del jugador al momento del Draft.
- **C Norm:** consiste de la conferencia donde participaba el equipo universitario del jugador, convertida en un valor entre 0 y 14.
- **Grade:** consiste de la puntuación de los expertos realizada para el jugador en el proceso previo al Draft.
- **SPORQ Normalizado:** consiste de la medición SPORQ de aptitud atlética, que es a su vez una aproximación de la medición SPARQ de Nike. Esta medición se realiza en base a los resultados obtenidos por el jugador en el NFL Draft Combine, previo al Draft.
- **AltAAV Cat:** Estas serán nuestras clases posibles. Será un número entre 0 y 2.

Clasificador. Para clasificar, utilizamos un **Perceptron Multicapa** de 4 capas ocultas, cada una con 128 neuronas. A su vez, el resto de los parámetros utilizados fueron:

- Learning Rate: 0.2
- Number of steps: 1000
- Batch size: 256
- Display step: 100
- Number of inputs: 6
- Number of classes: 3

3.2 Predicción del Draft

Set de Datos. Para el set de datos se utilizarán las mismas características que para la retrospección, pero omitiendo obviamente las dos características retrospectivas: DP Normalizado y Tm Normalizado, ya que en esta instancia (previo al Draft) serían desconocidas para nosotros.

Clasificador. Para el clasificador, se utilizará el mismo **Perceptron Multi-cap** de 4 capas ocultas, con los mismos parámetros utilizados anteriormente.

4 Resultados

4.1 Variación de parámetros

Antes de presentar los resultados, aclaramos que no haremos mayor hincapie en la variación de parámetros ya que la misma no entregó un cambio significativo en los resultados que veremos a continuación. Se intentó utilizar una mayor cantidad de capas (hasta 5) y neuronas por capa (hasta 1024), pero esto no hizo más que hacer la convergencia más lenta y no representó una mejora significativa en la precisión del algoritmo.

De esta forma, se volvió a la base que habíamos establecido con 4 capas ocultas y 128 neuronas por capa, que ofrecía los mismos resultados, pero con una convergencia mucho más rápida.

4.2 Retrospección del Draft

Precisión obtenida: Los resultados obtenidos fueron consistentemente superiores al 77%

4.3 Predicción del Draft

Precisión obtenida: Los resultados obtenidos fueron consistentemente superiores al 76%.

4.4 Análisis de los resultados

Vemos que los resultados son buenos ya que se predice de forma correcta en aproximadamente 3 de cada 4 instancias.

Asimismo, vemos que no hay mucha diferencia en precisión (1 o 2%) entre el aspecto retrospectivo y el predictivo de nuestro trabajo. Esto nos dice que las características retrospectivas, es decir, aquella información que obteníamos al transcurrir el Draft (posición de la selección y equipo que elige al jugador) no tienen una influencia muy drástica en la precisión. Basicamente, podríamos decir que no ofrecen mucha información.

En el siguiente apartado intentaremos analizar que significan estos resultados para nuestro problema a nivel general.

5 Conclusiones

5.1 Conclusiones de los resultados

La primera impresión que tenemos al ver los resultados es que el problema puntual que buscábamos resolver puede ser predicho con alta precisión. Sin embargo,

es nuestra obligación ver más allá de los resultados para analizar si la información que este trabajo nos brinda es verdaderamente de utilidad.

Lo primero a tener en cuenta es que la NFL es tal vez la liga más competitiva de los Estados Unidos y, debido al tamaño de sus plantillas y el rigor físico de la competencia que no existe en otros deportes, se vuelve muy complicado encontrar jugadores que sean capaces de mantener un alto nivel por un largo tiempo. Vemos así que existe una tendencia a una distribución irregular de los rendimientos de los jugadores en la liga. Lo que queremos decir con esto es que la mayoría de los jugadores no logra mantener un rendimiento alto a lo largo del tiempo, sea debido a lesión o a que físicamente se hace muy complicado.

De esta manera, nos encontramos con muchos jugadores de rendimientos regulares o malos, con algunos pocos jugadores verdaderamente "elite", que mantienen un nivel alto durante varias temporadas. Como es de esperar, estos jugadores se seleccionan al principio del Draft. El algoritmo nota esta tendencia y responde apropiadamente.

Yendo al caso puntual del Draft 2018, el cual utilizamos como parámetro para ver que resultados particularmente nos brindaba el algoritmo, vemos que se repite esta tendencia. El algoritmo nos da algunos jugadores de "elite" para seleccionar al principio del Draft (Sam Darnold, Bradley Chubb, Quenton Nelson), lo que finalmente termina ocurriendo, algunos jugadores que ve como potenciales buenos jugadores en el medio del Draft, y para el final del Draft la mayoría son jugadores "malos" que en pocos años abandonarán la liga.

5.2 Entonces, ¿qué utilidad nos brinda este trabajo?

Primero que nada, y como decíamos anteriormente, no pretendíamos con este trabajo llegar a una herramienta que nos brinde una respuesta absoluta a nuestro problema, ya que existen partes del mismo que no se pueden medir, como la pasión que un jugador tiene por el deporte, o su ética de trabajo, etc. Aún así, la herramienta puede ser utilizada para asistir a los profesionales en su proceso de evaluación de los candidatos, aunque sea teniéndola en cuenta como un factor más del mismo.

Si volvemos al caso puntual de 2018, vemos que surgen algunas particularidades que son interesantes:

- Durante todo el proceso de evaluación, hubo una disputa sobre quien era el mejor quarterback del draft (a su vez la posición más importante de este deporte, para contextualizar la importancia de esta discusión) y finalmente los Cleveland Browns se decidieron por Baker Mayfield. Algo a tener en cuenta es que el algoritmo favorecía ampliamente a Sam Darnold (elegido por los New York Jets con la 3era selección del Draft) y en base al conocimiento que el mismo tiene de los datos de años anteriores, la conclusión es que Mayfield no será un buen jugador en la liga. Podemos concluir que el primer año de Mayfield en la liga fue medianamente bueno (incluso mejor que el de Darnold), pero restan todavía algunos años para saber si la conclusión a la que la herramienta llegó fue la acertada o no.

- El algoritmo otorgó un buen resultado para algunos jugadores no tenidos tan en consideración por los expertos (Connor Williams y James Daniels) que posteriormente pasaron a tener buenas primeras temporadas con sus equipos y aparentan ser candidatos a tener largas y fructíferas carreras.

5.3 ¿Qué se puede mejorar?

Analizar este problema como un problema de regresión en vez de clasificación podría darnos una mejor perspectiva si lo que buscamos es encontrar alguna "joya" en las rondas más avanzadas del Draft. Encontrar valor a esa altura es algo que muchas veces termina siendo la diferencia entre los buenos equipos y los grandes equipos de la liga.

Por otro lado, y como suele suceder con trabajos de este tipo, incluir más datos para el entrenamiento de la herramienta probablemente nos brindaría mejores resultados.

Otro aspecto a tener en cuenta es la cantidad de clases que se utilizan para clasificar. Para la iteración actual, se utilizaron 3 clases (Bueno, Regular y Malo) con resultados bastante positivos. Aún así, la información que brinda una clasificación como esta no es tan atractiva. Se decidió, para el alcance de este trabajo, obviar la alternativa con 5 categorías (Muy Bueno, Bueno, Regular, Malo y Muy Malo) ya que la misma, obviamente, no obtenía resultados tan positivos como la de 3 clases (aproximadamente 57% de precisión). Teniendo en cuenta esto, podríamos pensar que si tuviéramos una cantidad mucho mayor de datos, podríamos obtener resultados similares con la clasificación de 5 clases a los obtenidos con la clasificación de 3 clases, de esta forma obteniendo conocimiento más útil.

5.4 Conclusión final

Como conclusión final, este trabajo nos muestra que en un proceso con tantos factores humanos imponderables, tal vez sea imposible acceder a una resolución unívoca de nuestro problema. Algunas cosas no pueden ser medidas sin tener un nivel de acceso con el que no contamos, y aún si lo tuviéramos seguirían existiendo aspectos de la conducta humana que no podríamos mensurar.

Habiendo dicho esto, podemos establecer definitivamente que esta herramienta tiene un cierto grado de utilidad y que podría ser efectiva asistiendo a los profesionales que participan del proceso de evaluación del Draft de la NFL, si bien no ofreciéndoles una conclusión avasallante, pero si brindándoles un factor más para tener en cuenta al momento de tomar una decisión que podría costar millones.

References

1. NATIONAL FOOTBALL LEAGUE DRAFT, *Artículo de Wikipedia de National Football League Draft*, Accedido el 20 de Febrero de 2019. https://en.wikipedia.org/wiki/National_Football_League_Draft

2. SPORQ, *Cálculo regresivo para aproximación de medición SPARQ de Nike*, Accedido el 21 de Febrero de 2019. <http://jhermsmeyer.com/sparq-scores>
3. PÁGINA OFICIAL DE LA NFL, *para selecciones posteriores a 2012*, Accedido el 21 de Febrero de 2019. <https://www.nfl.com/>
4. JEFF FEYERER, *periodista especializado del sitio insidethepylon.com*, Para selecciones entre 2002-2005. *Twitter oficial de Jeff Feyrer*, Accedido el 21 de Febrero de 2019 https://twitter.com/jeff_feyerer
5. PRO FOOTBALL REFERENCE, *Estadísticas de Fútbol Americano e historia*, Accedido el 21 de Febrero de 2019. <https://www.pro-football-reference.com/>